

Implementação e Análise de uma Rede Neural Artificial para Predição de Aquisição de Seguro de Viagem

Projeto Prático submetido para avaliação na disciplina de Computação Evolutiva e Conexão

Nomes:

Daniel Medici Martins (11202021642);

Ingrid Monteiro Maciel (11201932563);

Isabella Gomes Cardoso(11202520127).

Docente: Mateus Coelho Silva

Santo André
2026

SUMÁRIO

INTRODUÇÃO.....	2
REFERENCIAL TEÓRICO.....	3
METODOLOGIA.....	4
RESULTADOS E DISCUSSÃO.....	5
DECLARAÇÃO DE ÉTICA (IA GENERATIVA).....	7
CONCLUSÃO.....	8
REFERÊNCIAS.....	8

RESUMO

O objetivo principal deste trabalho foi o de apresentar o desenvolvimento e análise de uma Rede Neural Artificial baseada na tarefa de classificação de clientes em relação à probabilidade de aquisição de um seguro de viagem. A rede neural foi implementada na linguagem Python e foi utilizada uma base de dados pública com informações como: idade, renda anual, histórico de viagens, tipo de emprego e frequência de voos com o objetivo de identificar padrões nos dados e previsões com desempenho satisfatório.

INTRODUÇÃO

Nos últimos anos, técnicas de inteligência artificial e aprendizado de máquina têm sido cada vez mais utilizadas para apoiar a tomada de decisão em diferentes áreas, especialmente em problemas de classificação. Como afirma Sarker (2021), “Classification is regarded as a supervised learning method in machine learning, referring to a problem of predictive modeling [...]” Em termos gerais, esse tipo de problema busca analisar um conjunto de características de entrada para prever a qual classe uma determinada instância pertence. Na computação, esses métodos se destacam por sua capacidade de identificar padrões nos dados e apoiar aplicações voltadas à previsão, ao reconhecimento e à análise automatizada de informações.

No contexto do setor de seguros, esse tipo de abordagem se torna especialmente relevante, já que a atividade seguradora está diretamente relacionada ao conhecimento do risco e à identificação de perfis com maior aderência a determinados produtos. O estudo sobre a viabilidade de operação no ramo de seguro viagem mostra que esse segmento possui potencial estratégico para ampliação de portfólio e crescimento de vendas, além de destacar que fatores como momento da oferta, uso de tecnologia, qualidade do atendimento e definição adequada do público-alvo são importantes para o sucesso da comercialização (SANTOS et al., 2021).

Nesse cenário, prever quais clientes apresentam maior probabilidade de adquirir seguro viagem pode contribuir para tornar a oferta mais direcionada e eficiente. Neste trabalho, foi desenvolvido um modelo de rede neural para prever a contratação de seguro viagem com base nos dados dos clientes presentes na base utilizada. O foco do

experimento é observar o comportamento do modelo durante o treinamento e analisar seu desempenho por meio de métricas de avaliação aplicadas ao conjunto de testes.

REFERENCIAL TEÓRICO

Foi implementado um classificador neural de camada única (Perceptron), com múltiplas entradas e um único neurônio de saída. Nesse modelo, a saída é obtida a partir da combinação linear entre as entradas e os pesos da rede, acrescida de um termo de bias, seguida da aplicação de uma função de ativação.

Matematicamente, a combinação linear pode ser representada por:

$$u = X \cdot W^T$$

em que X representa o vetor de entrada com adição do bias (implementado no algoritmo como uma coluna adicional de uns) e W o vetor de pesos transposto (nesse caso não há matrizes, já que utilizaremos um neurônio). Em seguida, foi utilizada a função de ativação sigmóide, definida por:

$$\varphi(u) = \frac{1}{1 + e^{-u}}$$

Essa escolha é adequada para o problema tratado, pois a variável de saída é binária e a função sigmóide produz valores no intervalo contínuo entre 0 e 1, permitindo interpretar a saída do modelo como a probabilidade de a instância pertencer ou não à classe positiva.

A taxa de aprendizado será iniciada em "COEF_APREND" e submetida a um decaimento exponencial controlado pelo hiperparâmetro "dia", uma estratégia adotada para garantir passos maiores no início do treinamento e maior convergência final, como estudado em You et al. (2019) [5].

Os pesos da rede foram ajustados iterativamente com base no erro entre a saída prevista $\hat{y}$ e o valor esperado y . O critério de erro adotado foi o erro quadrático, expresso por:

$$E = (\hat{y} - y)^2$$

A atualização dos pesos seguiu a regra geral do gradiente descendente:

$$w_{i,j}^{[2]} = w_{i,j}^{[2]} - \eta_{epoch} \frac{\partial E}{\partial w_{i,j}^{[2]}}$$

Aplicando a regra da cadeia para a função sigmoide e o erro quadrático, a derivada utilizada no ajuste dos pesos é definida por:

$$\frac{\partial E}{\partial w_{i,j}^{[2]}} = 2(\hat{y}_i - y_i) \varphi(s)(1 - \varphi(s)) x_j$$

METODOLOGIA

O problema deste trabalho consiste na classificação da variável *TravelInsurance*, isto é, na previsão de contratação ou não de seguro de viagem a partir dos atributos disponíveis na base de dados.

Na etapa de pré-processamento, a base foi inicialmente embaralhada de forma aleatória. Em seguida, as variáveis categóricas foram convertidas em valores numéricos utilizando a técnica de Binary Encoding (mapeando categorias para 0 e 1), e as variáveis numéricas foram normalizadas utilizando uma variação do Min-Max Scaling. Essa normalização foi realizada dividindo-se cada atributo numérico (como renda anual, idade e número de familiares) pelo seu respectivo maior valor observado na base. O objetivo dessa etapa não foi tratar desbalanceamento, mas sim reduzir as diferenças de escala entre as variáveis, evitando que atributos com grandezas maiores tivessem influência desproporcional durante o treinamento. Após esse processo, os dados foram divididos: utilizaram-se 'N_TREINO' instâncias para o conjunto de treinamento, reservando-se as demais para o conjunto de testes.

O treinamento será realizado ao longo de "ÉPOCAS" épocas.

A cada dia in epoch:

$$\eta_{epoch} = \eta_0 * e^{-0.001 * epoch}$$

No algoritmo implementado, a saída predita é obtida pela função de ativação aplicada à soma ponderada das entradas. Em seguida, calcula-se o erro entre o valor previsto e o valor real, multiplica-se esse erro pela derivada da função sigmoide e, por fim, os pesos são atualizados com base na taxa de aprendizado vigente.

Além disso, foi atribuído um peso maior para os erros associados à classe positiva, definido pelo hiperparâmetro *W*. Essa estratégia foi adotada para lidar com a menor representatividade da classe buscada na base de dados, penalizando de forma mais severa os erros cometidos sobre ela. Isso aumenta a sensibilidade (Recall) do modelo na identificação de clientes reais, alinhando-se à premissa de negócio de que é preferível oferecer o seguro a mais clientes do que perder oportunidades de venda.

Para a busca de um coeficiente ideal, realizamos o treinamento de 0,60 até 0,11, o critério de escolha será aquele com melhor acurácia, balanceada também com o maior recall.


Para acompanhar o comportamento do modelo ao longo das épocas, foram calculados o Erro Quadrático Médio (MSE) e a acurácia no conjunto de teste. Ao final do treinamento, os resultados obtidos serão analisados por meio da matriz de confusão e das métricas de desempenho calculadas a partir dela (Precisão, Recall e F1) — medidas

usadas para avaliar quão bem a rede neural está classificando os clientes como pessoas que compram ou não seguro de viagem. É importante destacar que daremos prioridade ao Recall em relação à Precisão (ou Acurácia), visto que, para o nosso problema, o custo de oportunidade de um falso negativo (não oferecer o seguro a alguém que compraria) é maior do que o custo de um falso positivo (oferecer a quem não tem interesse).

RESULTADOS E DISCUSSÃO

Após várias iterações, fixamos os parâmetros e hiperparâmetros em:

Dado	Valor
COEF_APREND	0.23
N_TREINO	1500
EPOCAS	350
W	2.5
dias	30



Matriz de confusão

Métricas	Resultado (%)
Acurácia final	75.15
Precisão	67.88
Recall	62.22
F1-score	64.93

Tabela das métricas

Uma acurácia de aproximadamente 75% indicando que a maior parte das classificações realizadas pelo modelo foi correta.

A precisão é maior que o recall, o que não é ideal para o nosso modelo, mas entre os coeficientes de aprendizado, optamos pelo balanceamento entre acurácia e recall, devido ao ponto de vista do negócio estudado.




Gráfico Acurácia x época

A acurácia não mostrou muita evolução depois das 25 primeiras épocas, demonstrando que o erro encontrou rapidamente um mínimo e permaneceu nele até o fim; como não sabemos a natureza do problema, não sabemos se estamos num mínimo

global, ao executar múltiplas vezes, temos resultados similares mesmo com o começo de pesos aleatórios, o que entrega mais confiabilidade ao resultado.




Gráfico MSE x época

Esses resultados sugerem que o erro sistema se estabilizou por volta de 50 épocas, isso pode ser um indício que o modelo não está convergindo para um mínimo estável, já que a acurácia não cresce também, os degraus deixam explícito o efeito do decaimento do coeficiente de aprendizado; que diminui o tamanho dos passos a cada ciclo.

DECLARAÇÃO DE ÉTICA (IA GENERATIVA)

Esta seção estabelece as diretrizes de integridade seguidas no presente trabalho, detalhando o uso de modelos de linguagem de grande escala (LLMs). Nossa abordagem pauta-se nos princípios de transparência, supervisão humana e mitigação de vieses, garantindo que as ferramentas de IA atuem como suporte à produção intelectual, sem comprometer a autoria original ou a veracidade das informações apresentadas.

Neste trabalho usamos ferramentas de inteligência artificial como um apoio para revisão textual e algoritma, auxílio na estrutura e organização técnico científica, além de fonte de pesquisa para artigos reais.

Os autores, portanto, assumem total responsabilidade pela integridade, originalidade e precisão dos dados e argumentos apresentados; garantindo o rigor científico dessa produção.

CONCLUSÃO

Este trabalho buscou realizar o desenvolvimento de uma rede neural artificial classificando clientes e sua probabilidade de aquisição de seguros de viagem. Com base nisso, o modelo foi projetado com a finalidade de compreender de forma detalhada os processos matemáticos envolvidos no treinamento de redes neurais além de aplicar na prática conteúdos estudados em aula.

Os resultados obtidos demonstram que o modelo é capaz de identificar padrões relevantes nos dados e realizar classificações utilizando treinamento baseado no algoritmo de gradiente descendente e função de ativação sigmóide que é útil para problemas de classificação binária como este, no qual o modelo deve prever se um cliente irá adquirir ou não um seguro de viagem [2].

Entendemos que o modelo não concluiu completamente o objetivo; possíveis melhorias ao algoritmo são: o aumento da camada inicial de neurônios, adição de novas camadas, um estudo dedicado à otimização dos parâmetros e hiperparâmetros utilizados.

REFERÊNCIAS

- [1] Sarker IH. Machine Learning: Algorithms, Real-World Applications and Research Directions. SN Comput Sci. 2021;2(3):160. doi: 10.1007/s42979-021-00592-x. Epub 2021 Mar 22. PMID: 33778771; PMCID: PMC7983091.
- [2] SANTOS, Gabriel Lopes dos; BRITO, Anderson Odílio Lopes de; PEREIRA, Haroldo Luís Nascimento; NONATO, José Antônio Afonso; JUNIOR, Alberto de Medeiros; GHOBIL, Alexandre Nabil. Análise da viabilidade de operação no ramo de seguro viagem em companhia seguradora. EMPRAD - Encontro dos Programas de Pós-graduação Profissionais em Administração, 2021.
- [3] TEJASHVI. Travel Insurance Prediction Data. **Kaggle**, 2021. Disponível em: <https://www.kaggle.com/datasets/tejashvi14/travel-insurance-prediction-data>. Acesso em: 13 mar. 2026.
- [4] YOU, Yang et al. **How Does Learning Rate Decay Help Modern Neural Networks?**. 2019. Disponível em: <https://arxiv.org/abs/1908.01878>. Acesso em: 13 mar. 2026.